


মেশিন লার্নিং-এর গাণিতিক ভিত্তি

জ্যামিতি থেকে অ্যালগরিদম: ডেটা কীভাবে ভেক্টর ও ম্যাট্রিক্সে
রূপান্তরিত হয়



ডেটাকে ভেক্টরে রূপান্তর: টেবিল থেকে জ্যামিতি

টেবুলার ডেটা: শিক্ষার্থীর তথ্য


Study Hours	Play Hours	Result
7	1	Pass

ভেক্টর নোটেশন: x এবং y
ডাইমেনশনে রূপান্তর

$\begin{bmatrix} 7 \\ 1 \end{bmatrix}$

Input Vector: $[7, 1]$

2D স্পেস: গ্রাফে প্লটিং



মেশিন লার্নিং-এ ডেটাসেটের প্রতিটি সারি (row) হলো বহুমাত্রিক স্পেসের একটি নির্দিষ্ট বিন্দু।

ফাউন্ডেশন: স্কেলার বনাম ভেক্টর



স্কেলার (Scalar)

সংজ্ঞা: শুধুমাত্র মান (**Magnitude**) দ্বারা প্রকাশিত রাশি। কোনো দিক নেই।

উদাহরণ: তাপমাত্রা (**30°C**), অথবা মডেলের বায়াস (**Bias**)।

মেশিন লার্নিং ভূমিকা: ডেটা শিফটিং বা স্কেলিং করতে ব্যবহৃত হয়।




ভেক্টর (Vector)

সংজ্ঞা: মান (**Magnitude**) এবং দিক (**Direction**) উভয়ই রয়েছে।

উদাহরণ: **A** থেকে **B** এর দূরত্ব **১০ মিটার** ডানদিকে।

মেশিন লার্নিং ভূমিকা: ডেটা পয়েন্ট এবং ফিচারের জ্যামিতিক সম্পর্ক নির্ণয়ে ব্যবহৃত হয়।

ভেক্টর প্লটিং: জ্যামিতিক স্পেসে ডেটা




পাস (Pass): বেশি পড়াশোনা, কম খেলা।

ফেল (Fail): কম পড়াশোনা, বেশি খেলা।

নতুন ডেটা: [4, 1]। এই শিক্ষার্থী কি পাস করবে নাকি ফেল করবে?

অ্যালগরিদম এই প্রশ্নের উত্তর খোঁজে ভেক্টরগুলোর জ্যামিতিক অবস্থান বিশ্লেষণ করে।

জ্যামিতিক ক্লাসিফিকেশন: K-Nearest Neighbors (KNN)




প্রক্রিয়াটি বা নৈকট্য

মেশিন লার্নিং মডেল নতুন ভেক্টর এবং পরিচিত ভেক্টরগুলোর মধ্যকার ভৌত দূরত্ব (Physical Distance) পরিমাপ করে।

ফলাফল: যেহেতু (4, 1) বিন্দুটি লাল বিন্দু চেয়ে সবুজ Pass ক্লাস্টারের বেশি কাছাকাছি, মডেল প্রেডিক্ট করে যে এই নতুন শিক্ষার্থী পাস করবে।

এটি বিখ্যাত K-Nearest Neighbors (KNN) অ্যালগরিদমের মূল ভিত্তি!

ভেক্টরের মান (Magnitude): মূলবিন্দু থেকে দূরত্ব




L2 রেগুলারাইজেশন (Regularization): ওভারফিটিং রোধ করতে মডেলের বড় ওয়েট (Weights) গুলোকে পেনাল্টি দেওয়া হয়।

ফিচার ইম্পোর্টেন্স (Feature Importance): ভেক্টরের মান বড় হওয়ার অর্থ হলো সেই ফিচারের প্রভাব মডেলের ওপর বেশি।

এরর মেজারমেন্ট (Error Measurement): প্রেডিক্টেড ভ্যালু এবং আসল ভ্যালুর মধ্যকার জ্যামিতিক দূরত্ব পরিমাপ করা।

$$Distance = \sqrt{(x^2 + y^2)}$$

দুটি ভেক্টরের দূরত্ব: ইউক্লিডিয়ান ডিস্টেন্স



ধাপ ১: অনুভূমিক দূরত্ব (Base): $|2 - 6| = 4$


ধাপ ২: উল্লম্ব দূরত্ব (Height): $|5 - 3| = 2$

ধাপ ৩: পিথাগোরাসের সূত্র প্রয়োগ: যেহেতু দূরত্ব ঋণাত্মক হতে পারে না, তাই আমরা মানগুলোকে স্কয়ার (Square) করি।

$$\begin{aligned}\text{Distance} &= \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2} \\ &= \sqrt{16 + 4} \approx 4.47\end{aligned}$$


ডাইমেনশন স্কেলিং: 2D থেকে বহুমাত্রিক স্পেস (N-Dimensions)

2D




$$\sqrt{(x^2 + y^2)}$$

3D



$$\sqrt{(x^2 + y^2 + z^2)}$$

N-D




$$\sqrt{(x_1^2 + x_2^2 + \dots + x_n^2)}$$


জ্যামিতির সৌন্দর্য

- মেশিন লার্নিং ডেটাসেটে শত শত বা হাজার হাজার ফিচার (N-dimensions) থাকতে পারে।
- আমরা ১০০-মাত্রার ত্রিভুজ কল্পনা করতে না পারলেও, গাণিতিক যুক্তি সম্পূর্ণ অপরিবর্তিত থাকে!
- N-Dimensional সূত্র: **Distance** = $\sqrt{(x_n - y_n)^2 + \dots}$

স্কেলার অপারেশন: ডেটা শিফটিং বা মিন সেন্টারিং




স্কেলার যোগ: ভেক্টরের প্রতিটি উপাদানের সাথে নির্দিষ্ট মান যোগ করলে তা স্পেসে শিফট হয়।



স্কেলার বিয়োগ (Mean Centering):
ডেটাসেটের গড় মান (**Mean**) বের করে প্রতিটি পয়েন্ট থেকে বিয়োগ করলে, সম্পূর্ণ ডেটাসেট শূন্য (**Zero**) বরাবর কেন্দ্রভূত হয়।

ভেক্টর যোগফল: “টেল-টু-হেড” নীতি




হাঁটার রূপক (The Walking Metaphor)

- ভেক্টর A এর পথ ধরে হাঁটুন।
- A-এর মাথায় (Head) পৌঁছানোর পর, ভেক্টর V-এর লেজ (Tail) সেখানে বসান এবং তার পথ ধরে হাঁটুন।
- মূলবিন্দু থেকে আপনার চূড়ান্ত গন্তব্য পর্যন্ত আঁকা নতুন ভেক্টরটিই হলো যোগফল।

$$[1, 2] + [2, 3] = [3, 5]$$

ম্যাট্রিক্সের ডাইমেনশন: শেপ পাজল (The Shape Puzzle)



ম্যাট্রিক্স গুণের সুবর্ণ নিয়ম

প্রথম ম্যাট্রিক্সের কলাম (Columns) সংখ্যা অবশ্যই দ্বিতীয় ম্যাট্রিক্সের সারি (Rows) সংখ্যার সমান হতে হবে।

Status Box

ম্যাট্রিক্স ১: (1×3)

ম্যাট্রিক্স ২: (3×1)

স্ট্যাটাস: বৈধ (Valid)! ভেতরের সংখ্যাগুলো মিলে গেছে। নতুন ম্যাট্রিক্সের শেপ হবে (1×1) .

ম্যাট্রিক্স ট্রান্সপোজ (T): পাজল মেলানোর উপায়

সমস্যা: ভেতরের
ডাইমেনশন অমিল

(3×1)




(3×1)

ধরা যাক, দুটি কলাম ভেক্টর আছে: (3×1) এবং (3×1) ।
ভেতরের ডাইমেনশন মেলে না! গুণ করা অসম্ভব।

সমাধান: ট্রান্সপোজ (T)


(3×1)



ট্রান্সপোজ (T): ডায়াগনাল বরাবর
ম্যাট্রিক্সকে উল্টে দেওয়া। অর্থাৎ,
সারি (Row) হয়ে যাবে কলাম
(Column)।

ফলাফল: পাজল মেলানো


(1×3)



(3×1)

এখন সমীকরণটি হলো $(1 \times 3) \times (3 \times 1)$ । পাজলটি মিলেছে!

কোর এমএল অপারেশন ম্যাট্রিক্স (Core ML Operations)

	ইউক্লিডিয়ান ডিস্টেন্স (Euclidean Distance)	কোসাইন সিমিলারিটি (Cosine Similarity)	ডট প্রোডাক্ট (Dot Product)
কী পরিমাপ করে (Measures)	দুটি বিন্দুর মধ্যকার ভৌত দূরত্ব। $ d = \sqrt{(v_1)^2 + \dots p_2)^2}$	দুটি ভেক্টরের মধ্যকার কোণ (Angle), দূরত্ব নয়। $ a = \frac{\angle \theta}{ w_1 - w v_3 }$	একটি ভেক্টরের উপর অন্যটির ছায়া (Projection) এবং স্কেলার মান। $v_1 = v_1 \cdot w_2 + bias$
ভিজ্যুয়াল মেটাফর (Metaphor)	 স্কেল বা রুলার (Ruler)।	 চাঁদা (Protractor)।	 ছায়া (Shadow)।
মূল অ্যালগরিদম (Algorithm)	KNN ক্লাসিফিকেশন।	টেক্সট অ্যানালাইসিস এবং রেকমেন্ডেশন সিস্টেম।	নিউরাল নেটওয়ার্ক (Neural Networks) এবং PCA।

সিস্টেমস: নিউরাল নেটওয়ার্ক সমীকরণের এনাটমি

X (Data Vector)

ডেটা ভেক্টর। ইনপুট ফিচারের সারি।

W^T (Transposed Weights)

ট্রান্সপোজড ওয়েট ম্যাট্রিক্স। ম্যাট্রিক্স মাল্টিপ্লিকেশন বৈধ করার জন্য এটিকে ঘুরানো (T) হয়েছে।

$$y = X \cdot W^T + b$$


$\cdot$ (Dot Product)

ডট প্রোডাক্ট। ডাইমেনশন মিলিয়ে ইনপুট এবং ওয়েট গুণ করে একটি সিঙ্গেল স্কেলার আউটপুট তৈরি করে।

$+ b$ (Bias Scalar)

বায়াস (স্কেলার)। যোগ করার ফলে ডেটা স্পেসে শিফট হয়।

ম্যাক্রো ভিউ: সাপোর্ট ভেক্টর মেশিন (SVM)



হাইপারপ্লেন (Hyperplane)

ক্লাসের মধ্যে পার্থক্যকারী গাণিতিক সীমানা (Decision boundary)।

সাপোর্ট ভেক্টর (Support Vectors)

সীমানার সবচেয়ে কাছাকাছি থাকা ডেটা পয়েন্ট। মডেলটি শুধুমাত্র এই ভেক্টরগুলোর ওপর নির্ভরশীল।

ম্যাক্সিমাইজ মার্জিন (Maximizing Margin)

এই দুটি দলের মাঝখানের রাস্তা বা গ্যাপ সবচেয়ে চওড়া করা, যেন নতুন ডেটা নিখুঁতভাবে প্রেডিক্ট করা যায়।

ভেক্টরের দূরত্ব এবং জ্যামিতিই হলো মেশিন লার্নিংয়ের প্রকৃত মস্তিষ্ক!